

EXTRAÇÃO DE CONHECIMENTO E DADOS PARA A GESTÃO

PÓS GRADUAÇÃO EM
GESTÃO DOS SISTEMAS DE
INFORMAÇÃO EMPRESARIAIS





Índice da Apresentação



1. Descrição do Domínio



2. Preparação e limpeza dos dados



3. Análise Descritiva



4. Análise Preditiva



5. Conclusões, limitações e trabalho futuro

Metodologia Utilizada:

CRISP-DM (Cross-Industry Standard Process for Data Mining)

- Conhecimento do Negócio
- Conhecimento dos Dados
- Preparação dos Dados
- Modelação
- Avaliação
- Implementação

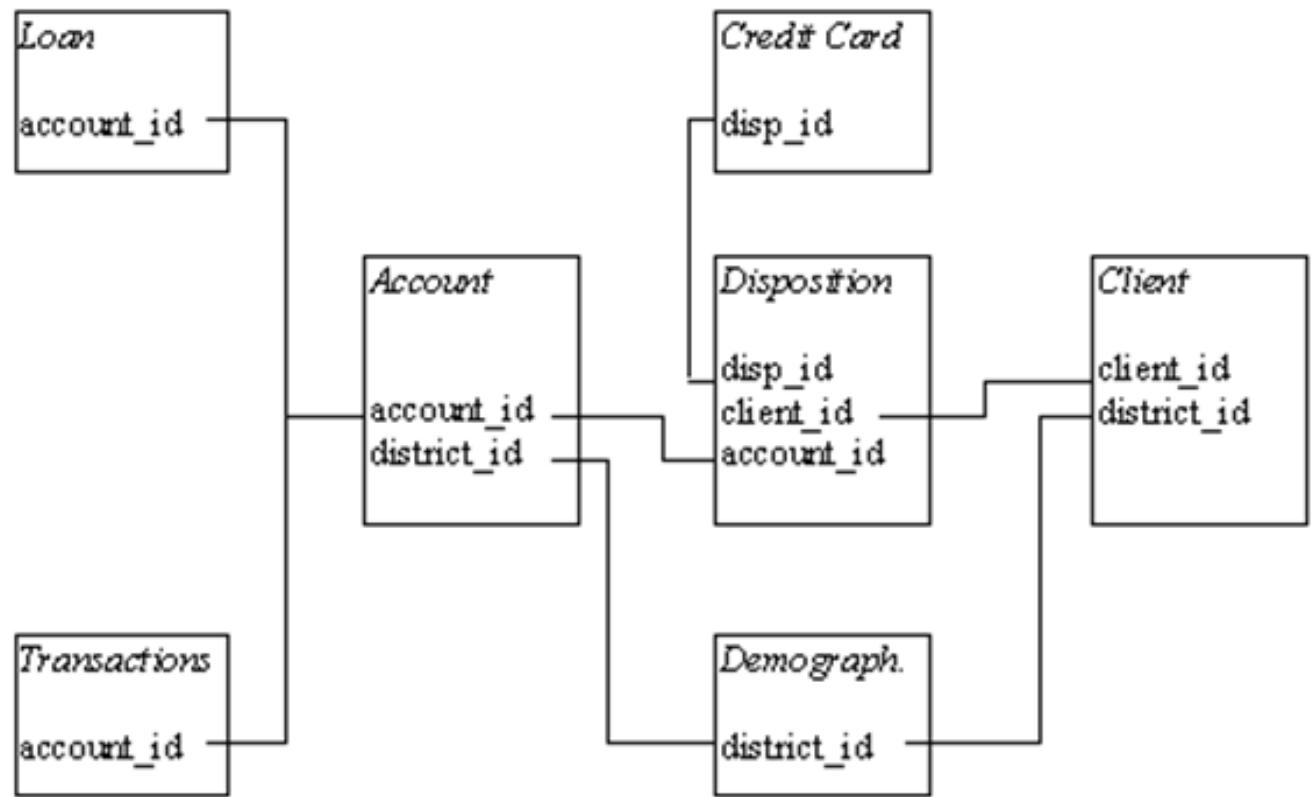


1. **DESCRIÇÃO DO DOMÍNIO**



Descrição do Domínio

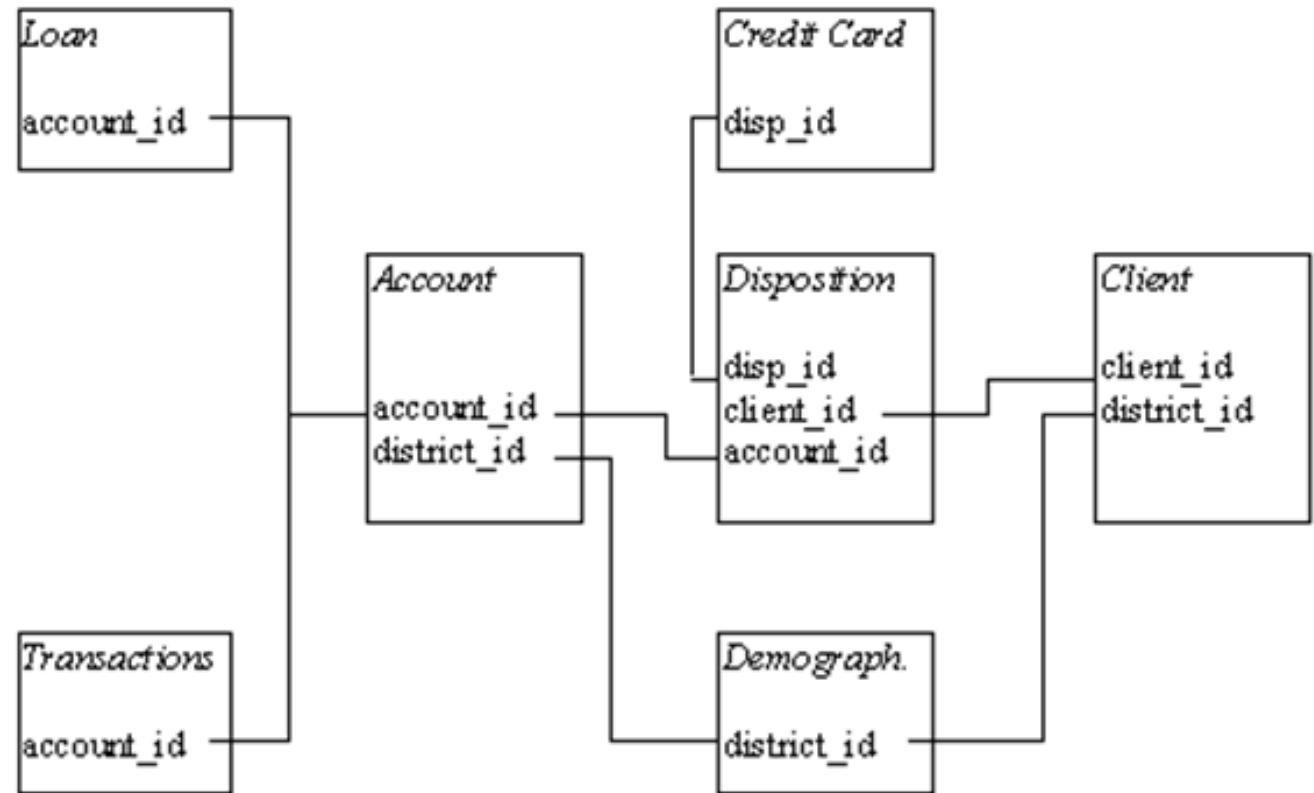
- O estudo do caso teve como principal objetivo a análise de dados de empréstimos de um Banco Checo, entre os anos de 1993 e 1996.
- Inclui informação relativa a clientes, dados geográficos, contas bancárias, empréstimos, cartões de crédito e movimentos bancários.
- Os dados encontram-se divididos entre dados de treino (análise histórica) e de teste (análise preditiva).



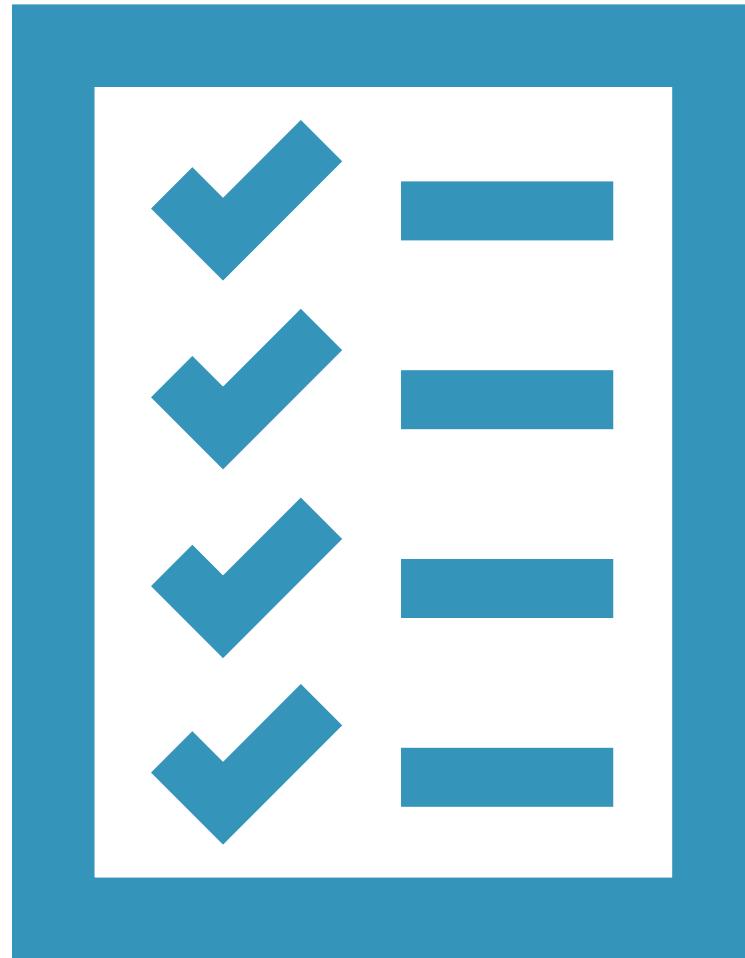
Descrição do Domínio

Os dados são compostos por:

- 4500 contas bancárias
- 5369 clientes
- 77 registos relativos a localizações geográficas
- 328 registos relativos a histórico de empréstimos
- 396,685 de registos relativos a histórico de transações



2. **PREPARAÇÃO E LIMPEZA DOS DADOS**



Preparação e limpeza dos dados

- ✓ Eliminar dados em falta
- ✓ Conversão de dados binomiais em dados numéricos
- ✓ Definir *roles*, *Ids* e *Labels*
- ✓ Converter campos numéricos em campos formato data
- ✓ Criação do atributo género do cliente
- ✓ Calcular a idade e data nascimento dos clientes

Preparação e limpeza dos dados

- ✓ Calcular se os clientes são adultos
- ✓ Calcular a antiguidade da conta (em dias)
- ✓ Determinar o proprietário da conta
- ✓ Converter os movimentos para débitos ou créditos
- ✓ Calcular o saldo médio, mínimo e máximo da conta
- ✓ Calcular o saldo à data do pedido de empréstimo

Preparação e limpeza dos dados



Calcular totais agregados por tipologia de movimento (entradas de bancos, saídas para cartão de crédito, etc)



Calcular o total de movimentos associados à conta bancária

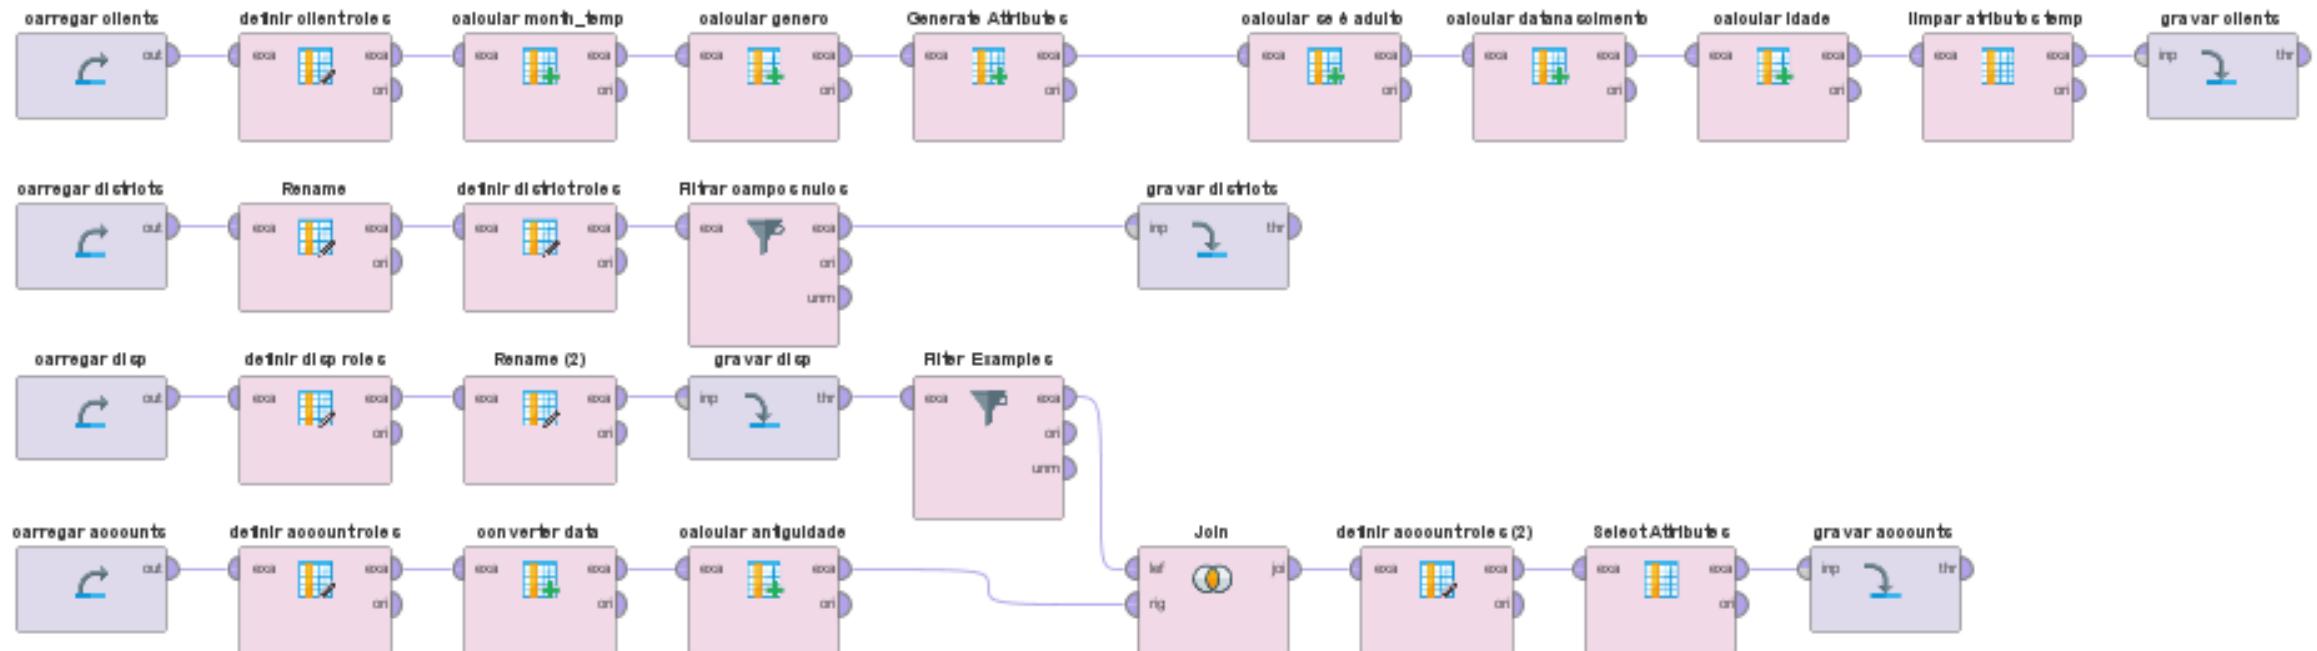


Determinar se existe cartão de crédito associado à conta bancária



Converter registos de localização em falta, através de regressão linear.

Preparação e limpeza dos dados



Preparação e limpeza dos dados

Exemplos de cálculo do género e da idade

Edit Parameter List: function descriptions

Edit Parameter List: function descriptions
List of functions to generate.

attribute name	function expressions
gender	if(parse(month_temp)>50, "woman", "male")
birth_number_format	if(parse(month_temp)>50, birth_number - 5000, birth_

Add Entry Remove Entry Apply Cancel

Edit Expression: function expressions

Expression

```
1 if @adult_temp == true, date_parse_custom(str(birth_number_format), "yyMMdd", "pt"), date_add(date_p
```

Info: Expression is syntactically correct.

Functions Search

- Logical
- Comparison
- Text information
- Text transformation
- Mathematical functions
- Statistical functions

Inputs Search

Regular Attributes

- # adult_temp
- # birth_number
- # birth_number_format
- # district_id
- # gender

Apply Cancel

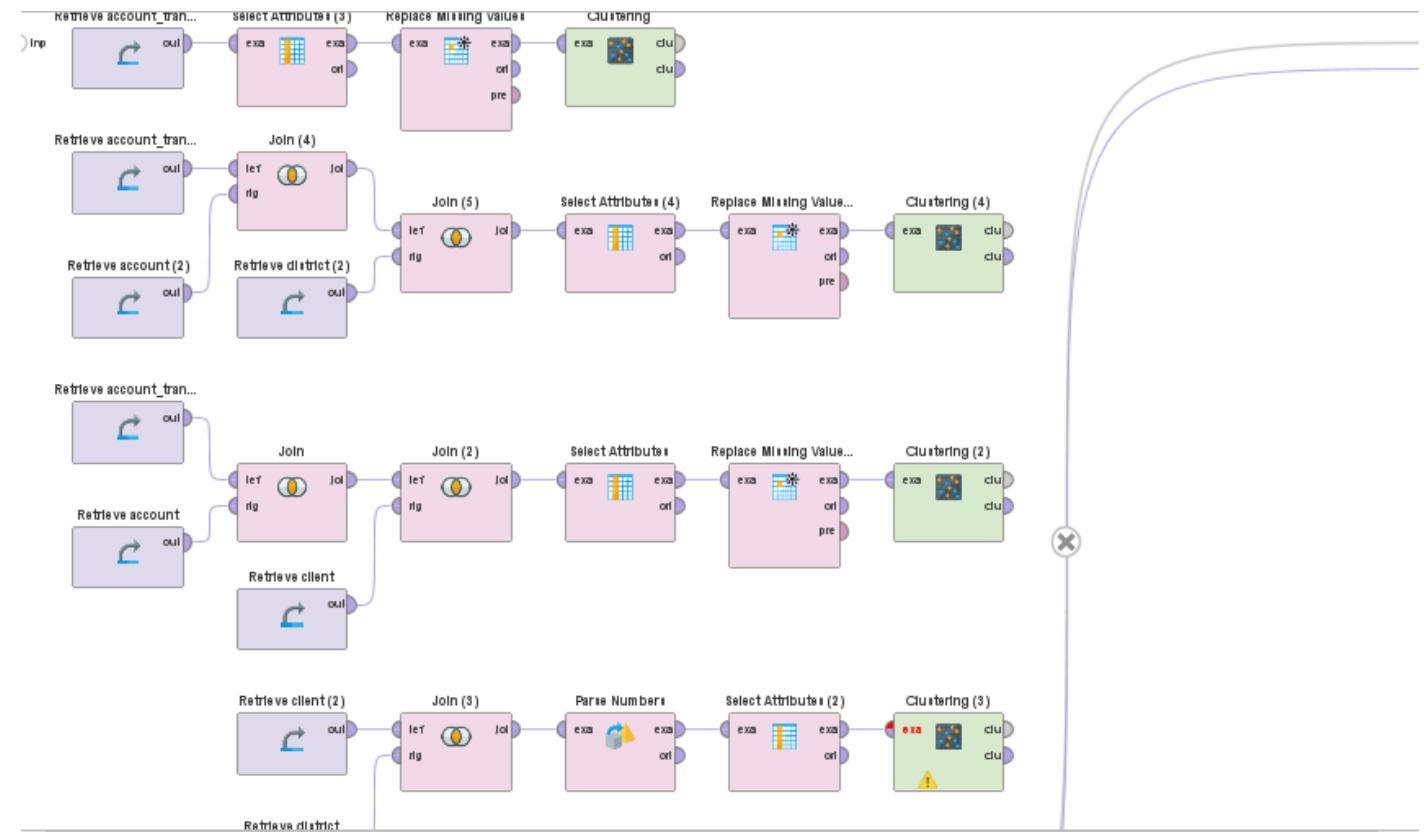
3. ANÁLISE DESCRITIVA

1010
1010

Análise Descritiva

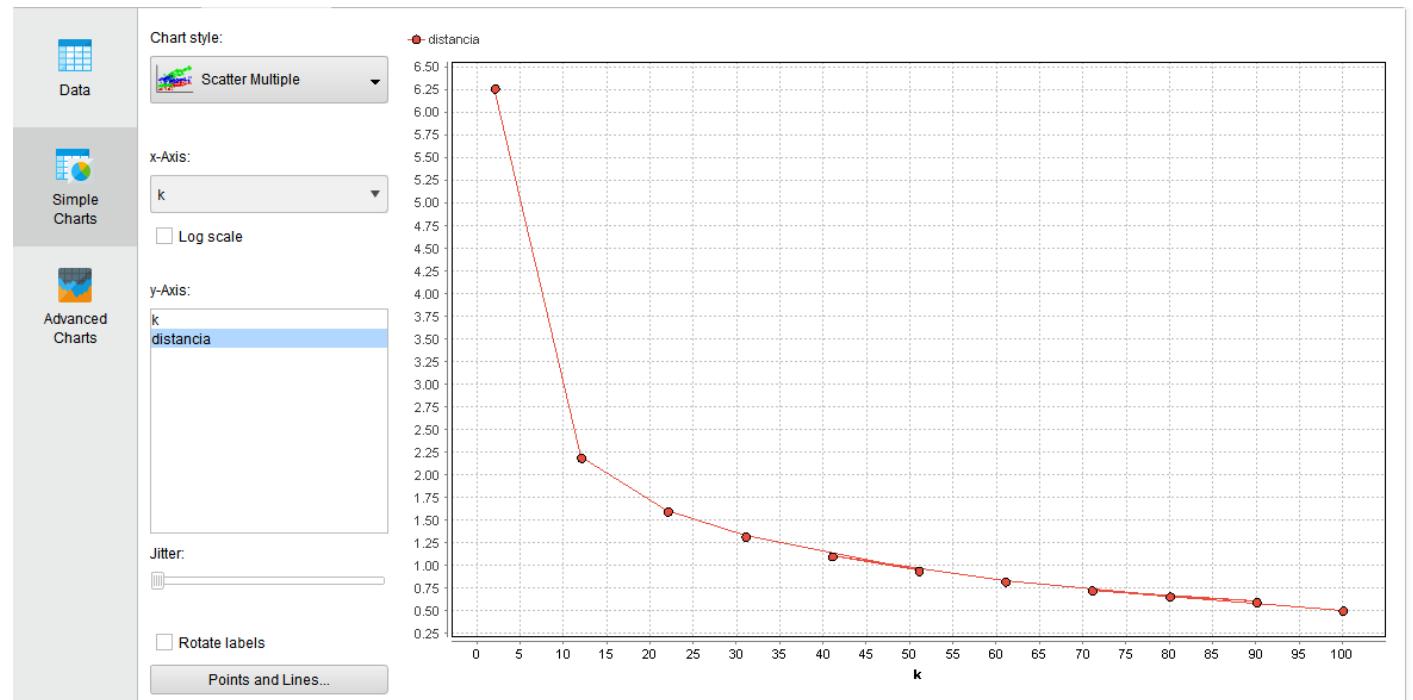
Através da ferramenta de clustering pretendeu-se fazer a segmentação dos dados relativos a clientes, nomeadamente:

- Género
- Idades
- Posição Financeira



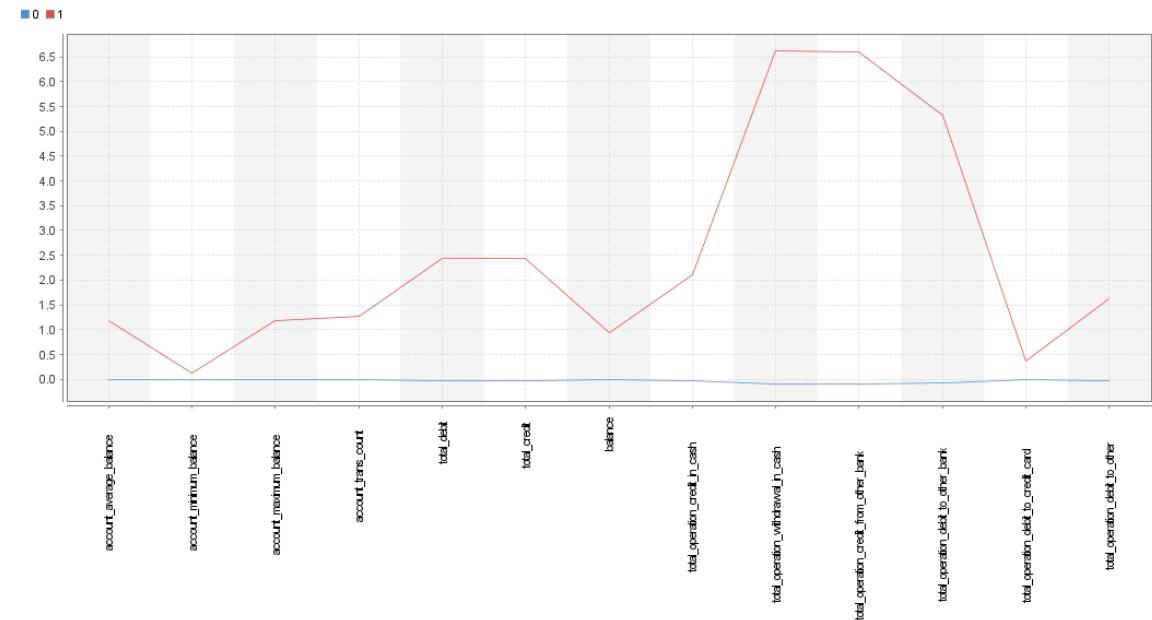
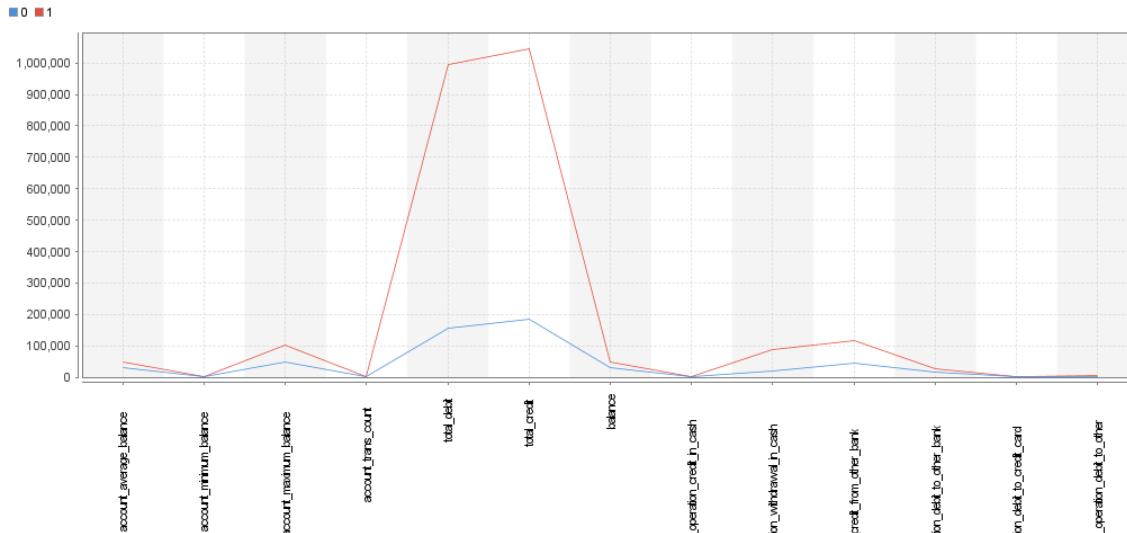
Análise Descritiva

- Determinação do melhor k para o clustering, utilizando o “Elbow method”



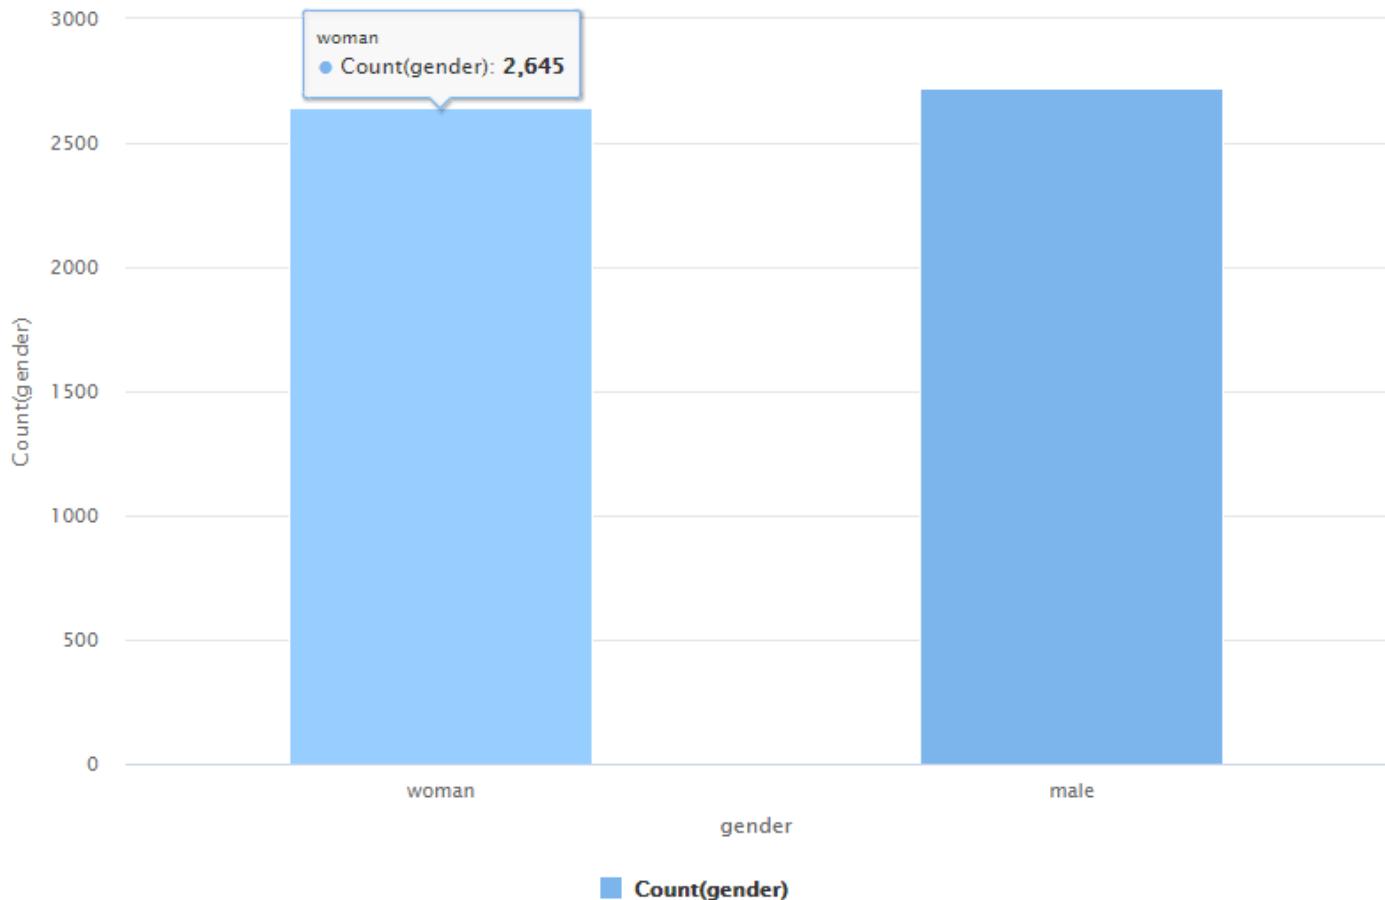
Análise Descritiva

- Normalização dos atributos para atenuar escalas grandes ou "ouliers"
- Neste caso em concreto, sem normalização apenas poderiam ser evidenciados os atributos totais de movimentos a débito e totais de movimentos a crédito.
- Com a normalização tornou-se mais fácil destacar os máximos, mínimos, médias e desvios dos restantes atributos



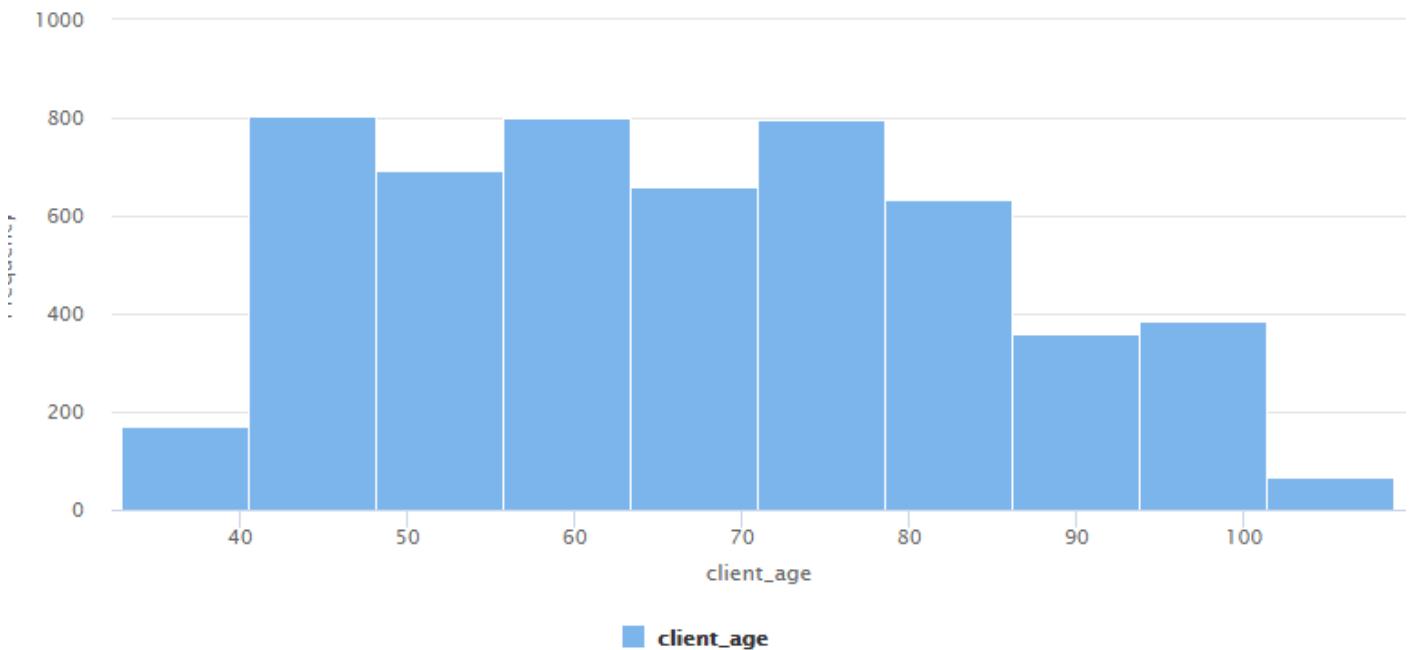
Análise Descritiva

- Relativamente ao género dos clientes estes são praticamente divididos igualmente entre homens e mulheres.
- O número de homens é 2724 e o número de mulheres é 2645.



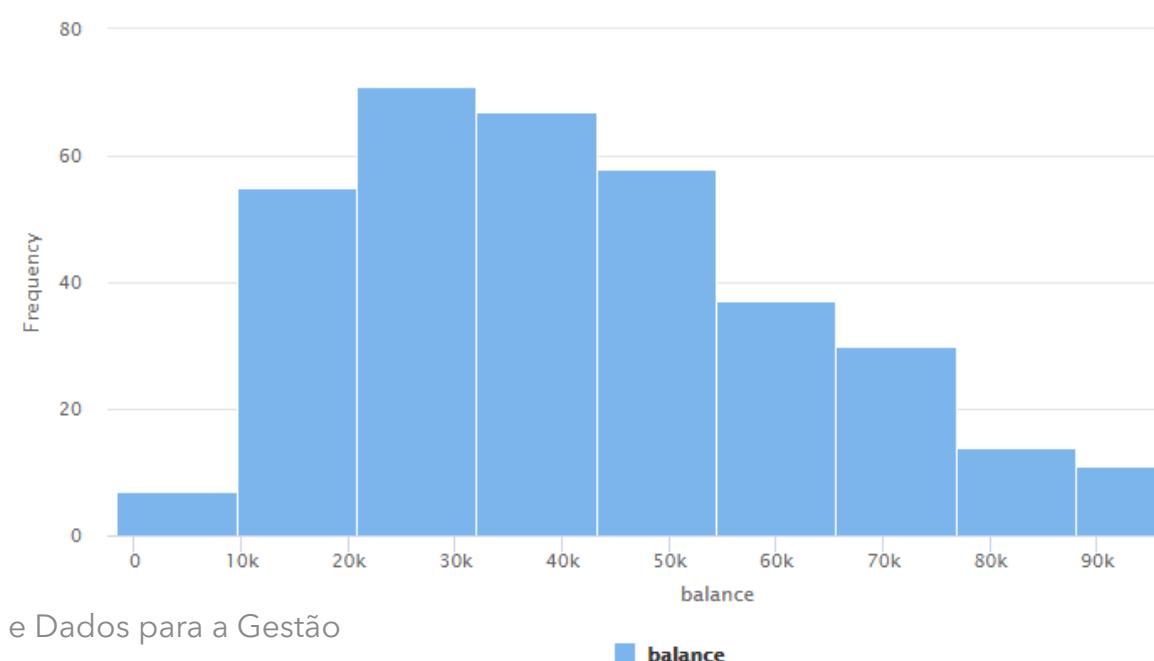
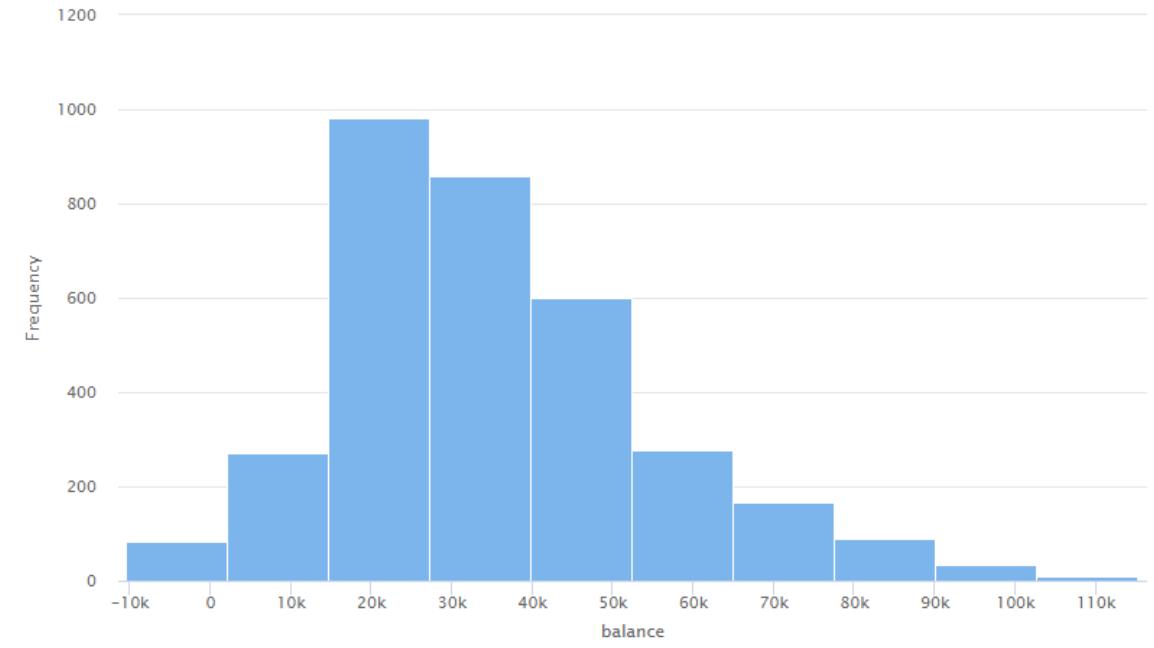
Análise Descritiva

- A maioria da população em análise tem idade compreendida entre 40 a 100 anos.
- Sendo a idade média de: 66,77 anos



Análise Descritiva

- A maioria das contas bancárias de treino apresenta um saldo bancário entre os 20k e os 40k.
 - O saldo médio é de 35,31k
-
- A maioria das contas bancárias de teste apresenta um saldo bancário entre os 30k e os 40k.
 - O saldo médio é de 42,40k



Clustering

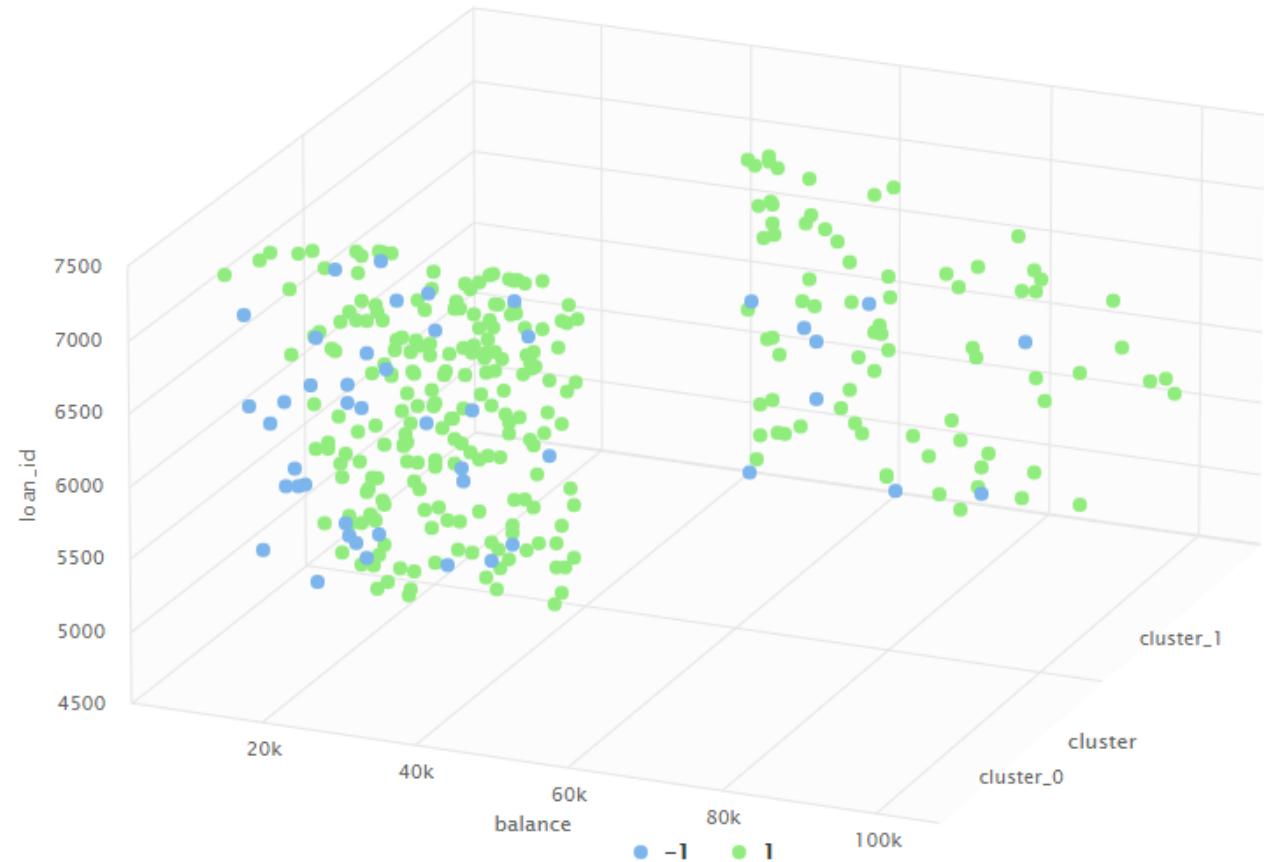
- Utilizando a técnica de clustering, e dividindo os dados em k=2 pode analisar-se algumas relações interessantes relativamente aos saldos médios, mínimos e máximos.
- Pode observar-se também que o salario médio não tem relação direta com o saldo médio.

Attribute	cluster_0	cluster_1
account_average_balance	28765.105	48996.021
account_minimum_balance	706.630	557.738
account_maximum_balance	49481.359	102977.329
account_trans_count	92.811	222.103
total_debit	154538.806	995533.329
total_credit	186425.107	1045202.107
balance	31886.301	49668.778
total_operation_credit_in_cash	1285.263	1134.361
total_operation_withdrawal_in_cash	20569.195	88226.240
total_operation_credit_from_other_bank	44184.664	117472.963
total_operation_debit_to_other_bank	17720.875	25649.783
total_operation_debit_to_credit_card	240.463	3049.307
total_operation_debit_to_other	1986.557	7057.815

Attribute	cluster_0	cluster_1
account_average_balance	48071.227	22400.557
average salary	9445.932	9442.822

Clustering

- Neste exemplo podem observar-se 2 clusters, relacionando os atributos saldo e o resultado do pagamento do empréstimo (dados de treino).
- Importância do atributo Saldo no pagamento dos empréstimos.
Normalmente, quem tem saldos maiores paga os empréstimos.

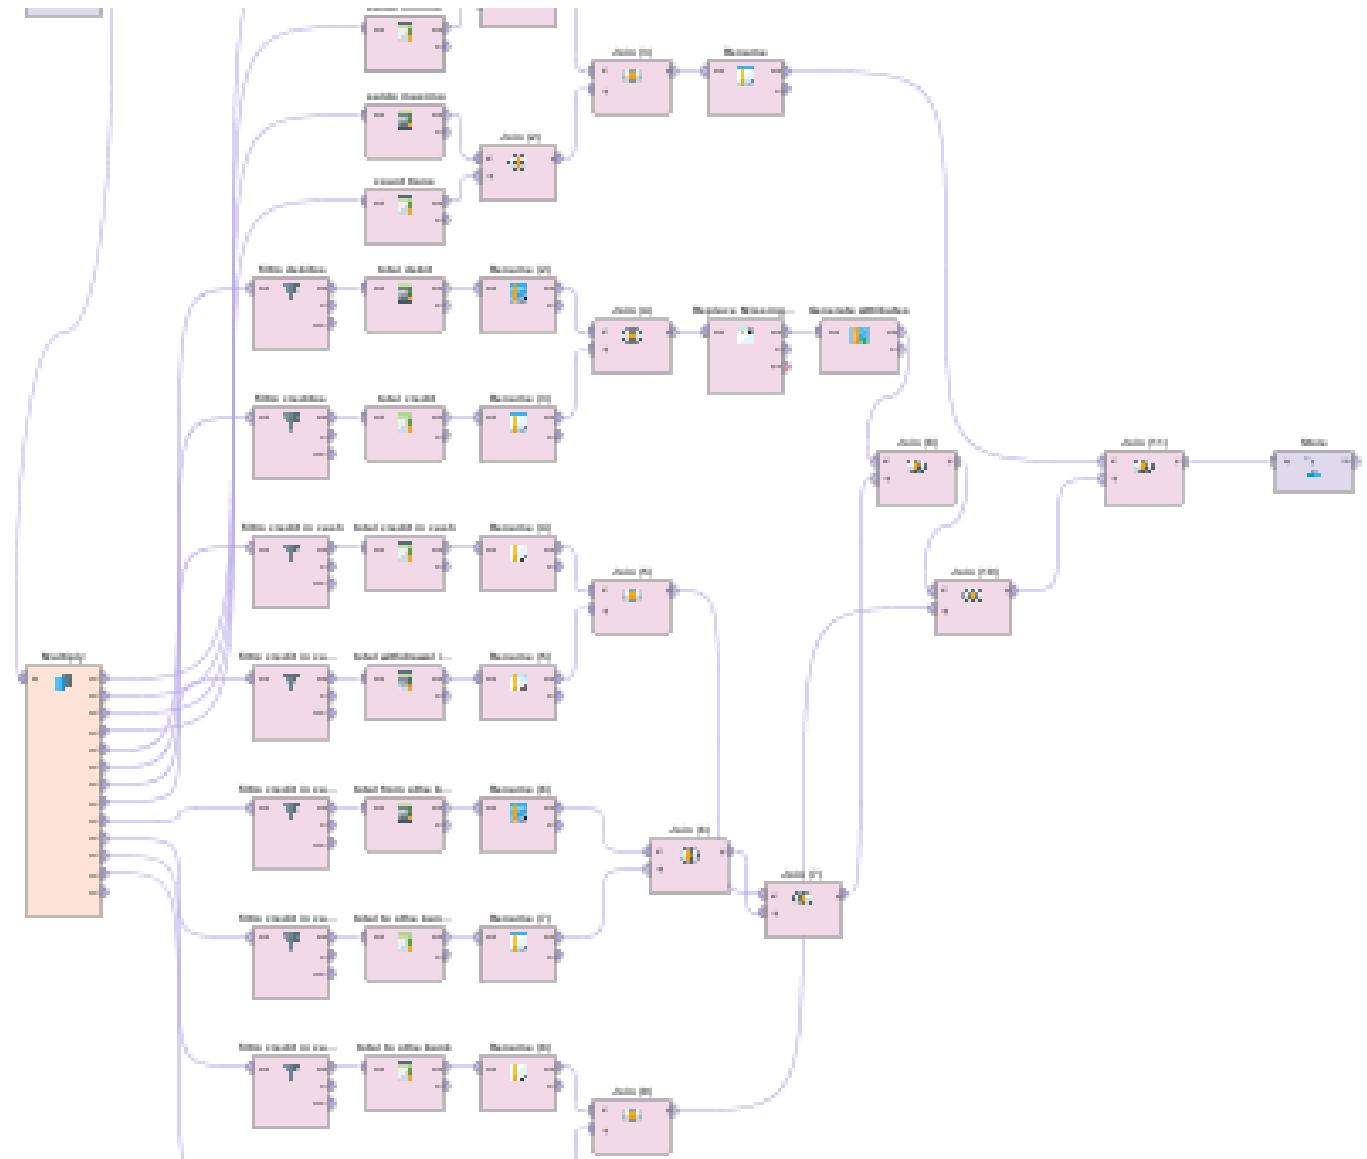


4. ANÁLISE PREDITIVA



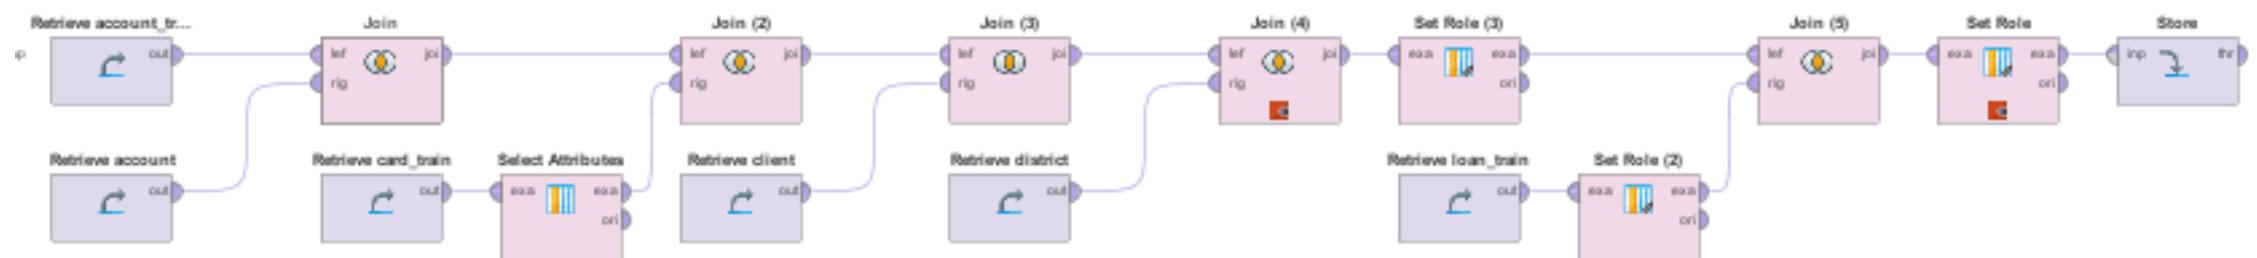
Análise Preditiva

Cálculo de novos atributos de contas bancárias (saldos, totais de movimentos) com operadores “aggregation”.



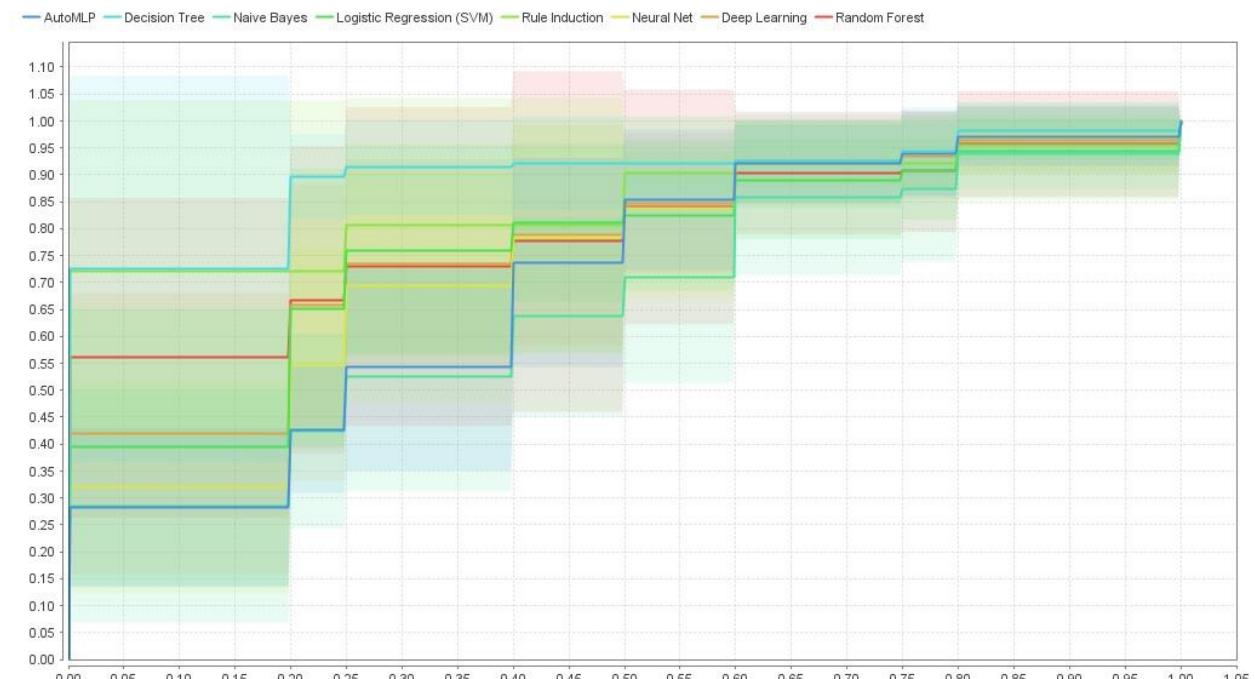
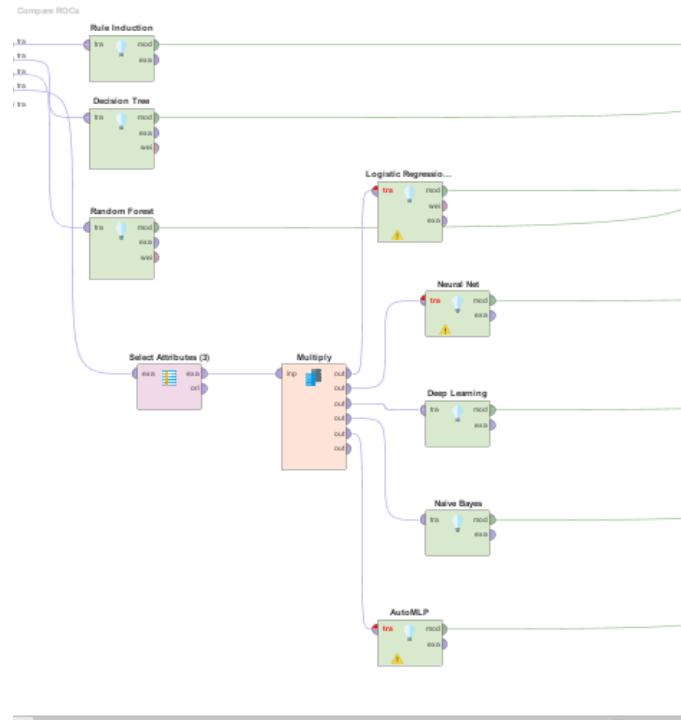
Análise Preditiva

Agrupamento da Informação com operadores “Join”



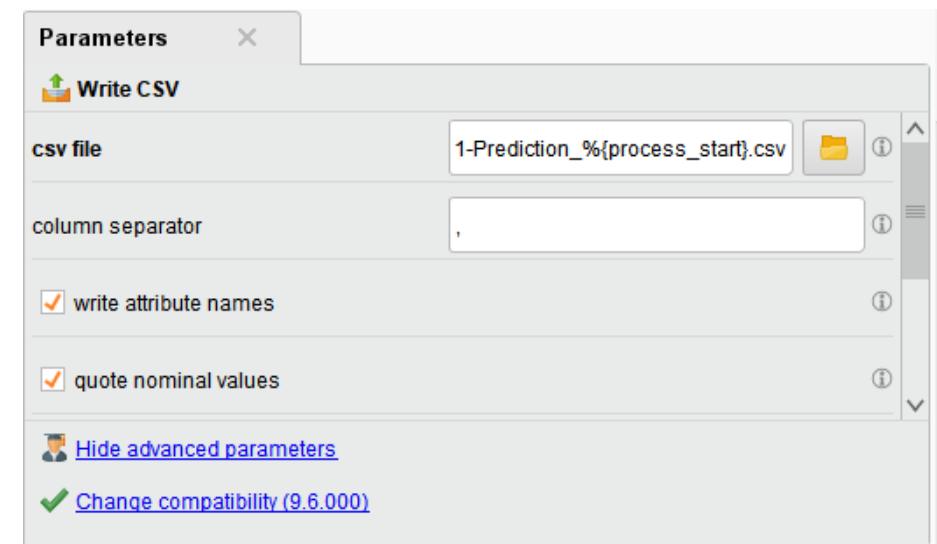
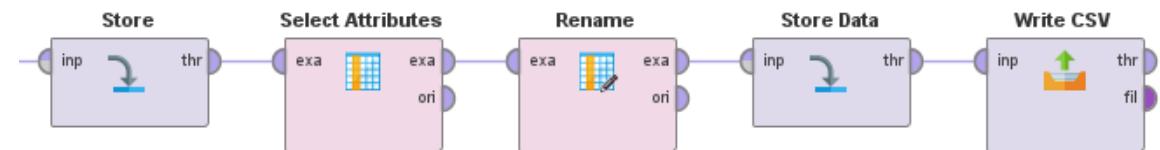
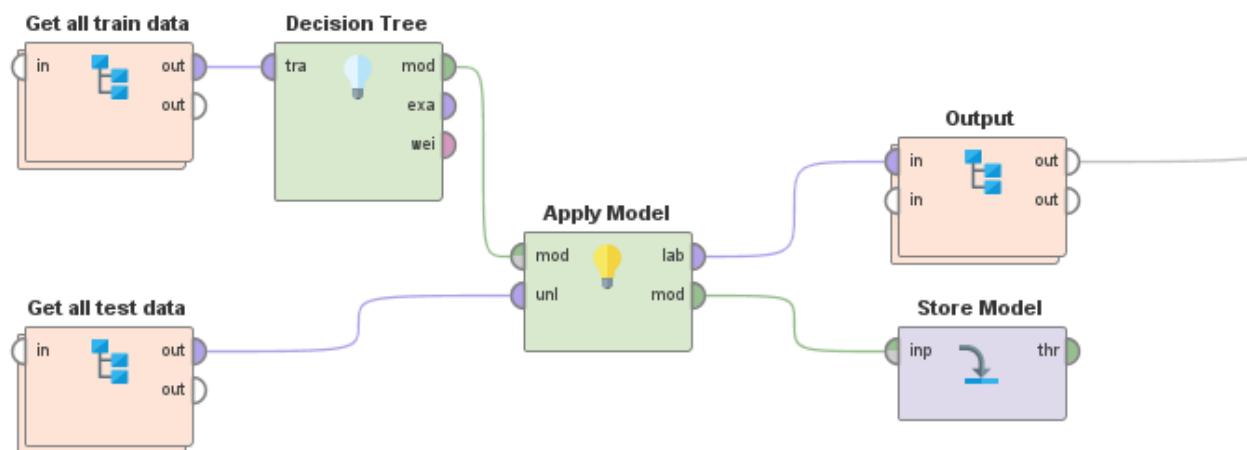
Análise Preditiva

- A curva ROC (Receiver Operating Curve) representa a taxa de verdadeiros positivos (TVP) em função da taxa de falsos positivos (TFP).
- Comparação dos vários modelos de previsão, utilizando o melhor ROC como critério de seleção.
- Neste caso, a árvore de decisão (decision tree) apresentou os melhores resultados.



Análise Preditiva

- Criação do modelo de previsão (decision tree)
- Geração dos resultados finais utilizando parâmetros do sistema `%{process_start}` para a criação do CSV.

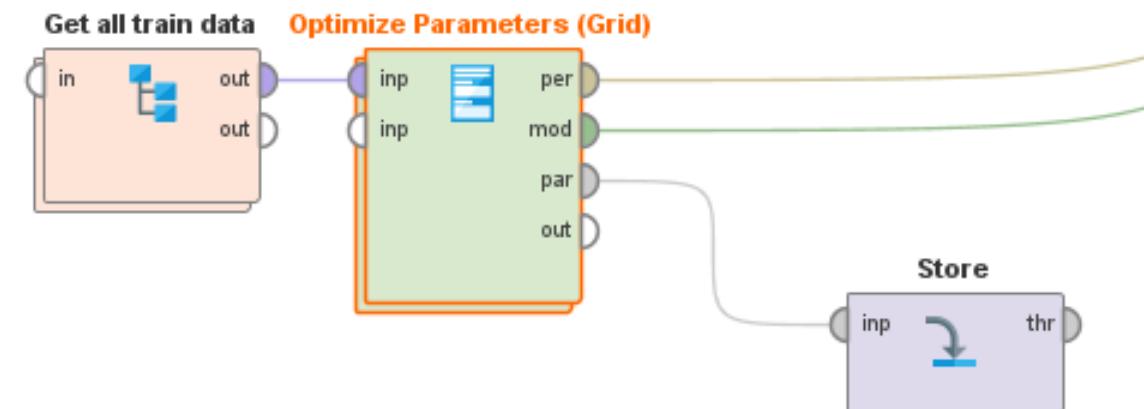


Análise Preditiva

- Otimização dos parâmetros da decision tree

ParameterSet

```
Parameter set:  
  
Performance:  
PerformanceVector [  
-----accuracy: 96.92%  
ConfusionMatrix:  
True: -1      1  
-1:   7      0  
1:    2     56  
]  
Decision Tree (2).criterion      = gain_ratio  
Decision Tree (2).maximal_depth = 9  
Decision Tree (2).minimal_leaf_size      = 1  
Decision Tree (2).minimal_size_for_split      = 70  
Decision Tree (2).confidence      = 0.10000008
```



Análise Preditiva

- Visualização dos detalhes da decision tree

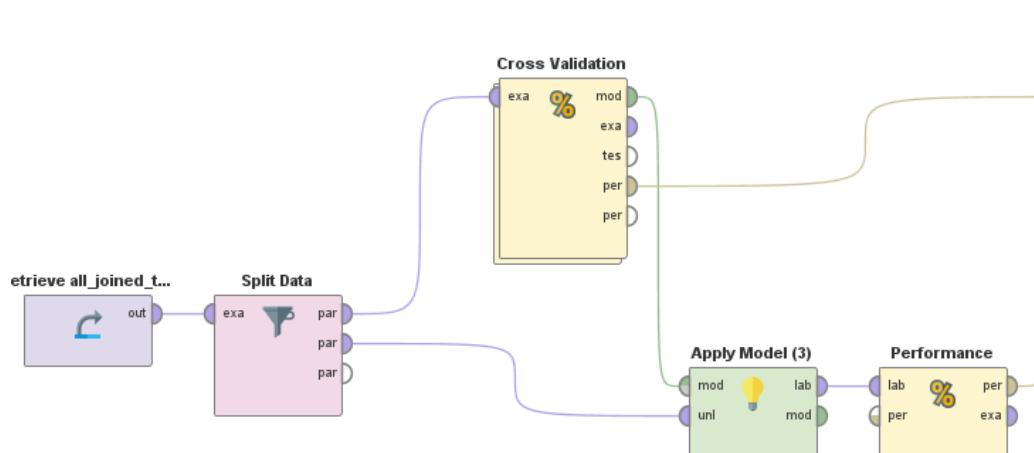


Tree

```
account_minimum_balance > 54.050
| account_average_balance > 19707.448
| | account_maximum_balance > 179279.250: -1 {-1=1, 1=0}
| | account_maximum_balance <= 179279.250
| | | amount > 454692: -1 {-1=2, 1=2}
| | | amount <= 454692
| | | | account_trans_count > 12.500
| | | | | total_credit > 67937.450
| | | | | | balance > 16036.550
| | | | | | | client_birthdate > Feb 1, 1938 11:30:00 PM GMT
| | | | | | | | account_maximum_balance > 158108.450: 1 {-1=1, 1=2}
| | | | | | | | account_maximum_balance <= 158108.450
| | | | | | | | | client_birthdate > Jun 28, 1939 12:00:00 AM BST
| | | | | | | | | | account_trans_count > 13.500
| | | | | | | | | | | total_credit > 77787.750: 1 {-1=7, 1=247}
| | | | | | | | | | | | total_credit <= 77787.750: -1 {-1=1, 1=1}
| | | | | | | | | | | | | account_trans_count <= 13.500: 1 {-1=1, 1=3}
| | | | | | | | | | | | | | client_birthdate <= Jun 28, 1939 12:00:00 AM BST: 1 {-1=2, 1=5}
| | | | | | | | | | | | | | | client_birthdate <= Feb 1, 1938 11:30:00 PM GMT: 1 {-1=2, 1=4}
| | | | | | | | | | | | | | | | balance <= 16036.550: 1 {-1=5, 1=10}
| | | | | | | | | | | | | | | | | total_credit <= 67937.450: -1 {-1=3, 1=3}
| | | | | | | | | | | | | | | | | | account_trans_count <= 12.500: 1 {-1=4, 1=5}
| | | | | | | | | | | | | | | | | | | account_average_balance <= 19707.448: -1 {-1=4, 1=0}
| | | | | | | | | | | | | | | | | | | account_minimum_balance <= 54.050: -1 {-1=13, 1=0}
```

Análise Preditiva

- Medição da performance do modelo
- Cross Validation: 91,19% +/- 3,26%
- Performance Vector: 93,94%
- Split Data: 90% + 10%



accuracy: 93.94%

	true -1	true 1	class precision
pred. -1	3	0	100.00%
pred. 1	2	28	93.33%
class recall	60.00%	100.00%	

accuracy: 91.19% +/- 3.26% (micro average: 91.19%)

	true -1	true 1	class precision
pred. -1	21	6	77.78%
pred. 1	20	248	92.54%
class recall	51.22%	97.64%	

Análise Preditiva

- Pontuação na competição kaggle
- A discrepância de resultados justifica-se pelo overfit do modelo, perante dados não conhecidos

Public Leaderboard Private Leaderboard

This leaderboard is calculated with approximately 50% of the test data.
The final results will be based on the other 50%, so the final standings may be different.

Raw Data Refresh

#	Team Name	Notebook	Team Members	Score ⓘ	Entries	Last
1	Grupo 1			0.90246	44	2d

Your Best Entry ↑
Your submission scored 0.90246, which is an improvement of your previous score of 0.86913. Great job! Tweet this!

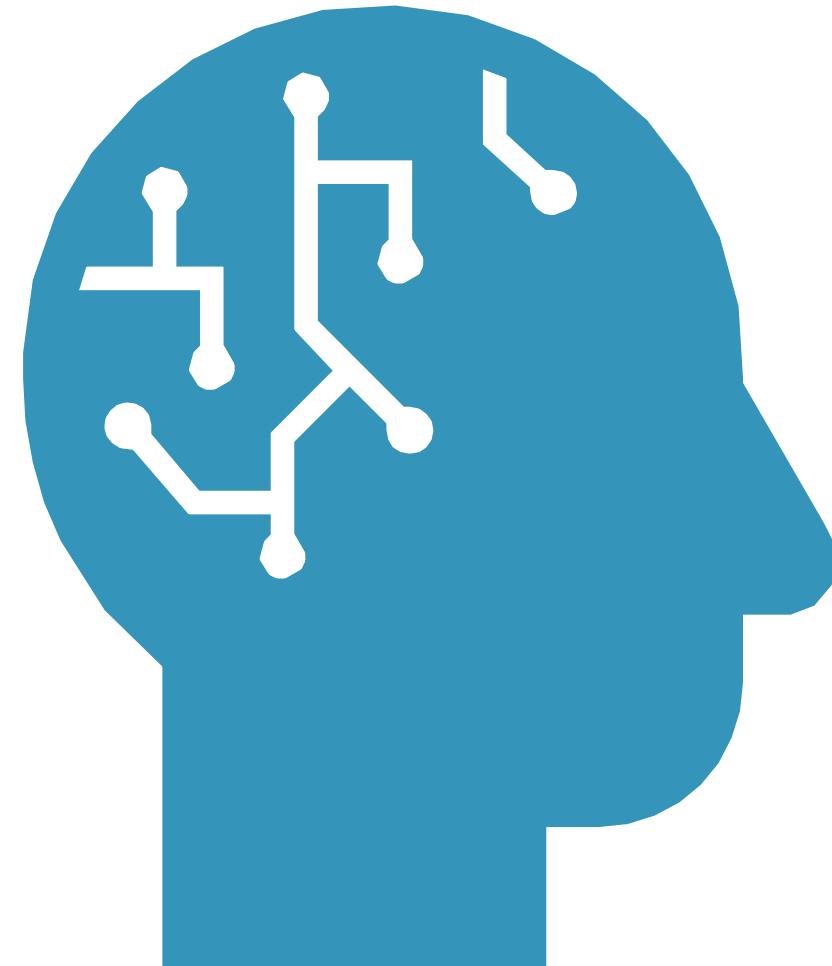
Public Leaderboard Private Leaderboard

The private leaderboard is calculated with approximately 50% of the test data.
This competition has completed. This leaderboard reflects the final standings.

Refresh

#	△pub	Team Name	Notebook	Team Members	Score ⓘ	Entries	Last
1	▲ 4	Grupo 2			0.75370	18	4d
2	▼ 1	Grupo 1			0.72654	93	5d

5. CONCLUSÕES, LIMITAÇÕES E TRABALHO FUTURO



CONCLUSÕES, LIMITAÇÕES E TRABALHO FUTURO

Os objetivos deste trabalho foram:

- Encontrar relações entre os atributos através da aplicação de técnicas de aprendizagem automática de dados;
- Criar modelos “inteligentes” capazes de auxiliar os bancos na tomada de decisão quanto à concessão de empréstimos aos seus clientes.

CONCLUSÕES, LIMITAÇÕES E TRABALHO FUTURO

A escolha dos atributos relevantes foi essencial para criar um modelo com a maior precisão possível.

A escolha errada de atributos ou em grande número, origina o “overfitting” provocando a degradação da performance do modelo e originando muitos falsos positivos e falsos negativos.

A comparação entre os diferentes algoritmos revelou que a árvore de decisão apresenta o melhor ROC.

Os dados de treino deveriam ser em maior número e cobrir mais anos de análise para melhorar a performance do modelo de previsão.

No futuro seria interessante estudar os dados relativos a mais anos de treino e comparar as respetivas previsões.

OBRIGADO !

